

EEG 数据增强技术：演进脉络、工程挑战与未来展望

A Survey of EEG Data Augmentation: Evolution, Engineering Challenges, and Future Directions

代子祥，汤仲宇，施政宇，刘卓函

电子科技大学，成都，610054

摘要

【摘要】脑电图（Electroencephalogram, EEG）信号具备样本规模有限、信噪比偏低、非平稳性明显以及个体间差异显著等特点，这些特共同制约了深度学习模型在处理此类数据时的泛化性能。因此，数据增强技术成为提升模型鲁棒性与适应能力的关键途径。本文从软件工程与机器学习相结合的跨学科视角，对 EEG 数据增强技术的演进脉络进行了系统梳理，并将其发展历程划分为四个递进的阶段。演进过程起始于依赖信号处理理论的确定性增强方法，随后过渡至基于样本插值的正则化增强策略，进而发展为以生成对抗网络及扩散模型为代表的概率生成增强技术，最终演进至当前以前沿的自监督学习与对比学习为核心的隐式增强范式。本文的核心学术贡献主要体现在以下四个方面：其一，本文提出了一个能够统一描述该领域技术发展的四范式分类框架；其二，本文揭示了其中存在的三大关键工程挑战，即表征物理约束的有效融入、系统性评估维度的相对缺失，以及实际部署中资源消耗与性能的权衡问题；其三，本文通过设定极端小样本、类别不平衡、高个体差异性以及实时性约束四类典型的数据困境与应用场景，实证性地剖析并界定了不同增强方法的有效性与适用边界；其四，本文进一步展望了未来若干关键研究方向，包括轻量化生成技术、多模态信息引导增强以及标准化评估体系的构建，旨在推动 EEG 数据增强技术从依赖经验的技巧性实践，转变为具备可验证性与可部署性的系统性工程实践。

关键词：脑电图；数据增强；生成模型；自监督学习；工程评估；

摘要

Abstract: The inherent characteristics of Electroencephalogram (EEG) signals—such as small sample sizes, low signal-to-noise ratio, non-stationarity, and significant inter-subject variability—severely limit the generalization capability of deep learning models, making data augmentation a key technology for enhancing robustness. From the cross-perspective of software engineering and machine learning, this paper systematically reviews the four-stage evolutionary trajectory of EEG data augmentation: from deterministic augmentation based on signal processing, to regularization augmentation based on sample interpolation, then to probabilistic generative augmentation based on generative models (GAN/Diffusion Models), and finally

developing into an implicit augmentation paradigm centered on self-supervised and contrastive learning. The core contributions of this paper include:(1) proposing a unified four-paradigm classification framework; (2) revealing three major engineering challenges: representation physical constraints, lack of evaluation dimensions, and deployment resource trade-offs; (3) empirically analyzing the effectiveness boundaries of various augmentation methods through four typical data dilemmas: extreme small samples, class imbalance, high inter-subject variability, and real-time constraints; (4) looking forward to future directions such as lightweight generation, multimodal guidance, and standardized evaluation, promoting the transition of EEG data augmentation from empirical tricks to verifiable and deployable engineering practices .

Key words: Electroencephalogram; Data Augmentation; Generative Models; Self-supervised Learning; Engineering Evaluation

1 引言

1.1 EEG 数据分析的独特挑战

脑电作为一种非侵入式的神经生理监测技术，以其毫秒级的高时间分辨率特性，成为探测大脑活动的重要工具。该技术在脑机接口系统、神经系统疾病辅助诊断以及认知机理研究等诸多领域，均发挥着不可替代的关键作用。

然而，基于 EEG 信号构建的深度学习模型在迈向实际应用时，首先面临着一系列源于数据本质属性的严峻挑战。其中，EEG 信号固有的低信噪比与显著的非平稳性构成核心难点。具体而言，大脑皮层产生的微弱电信号极易受到来自眼动、肌肉收缩等多种生理伪迹的干扰与污染^[1]。与此同时，信号的统计特征会随被试者的生理状态、注意力水平及实验环境等因素而随时间动态变化。这种敏感且易变的脆弱属性，对模型的鲁棒性与泛化能力提出了极高的要求。

其次，个体间以及同一受试者不同会话间存在的显著差异，构成了模型实现跨主体与跨会话泛化的核心障碍。具体而言，不同受试者的大脑在解剖结构、功能连接模式等方面均存在固有差异。此外，即便是同一个人，其在不同实验会话中的心理状态、注意力集中度乃至环境因素的变化，均可能导致所采集 EEG 数据的概率分布发生漂移^[2-3]。这种由主体内与主体间变异性所导致的数据分布不一致性，使得在单一被试或有限会话数据上训练并表现优异的模型，在面对新被试或新会话数据时，其性能往往会出现显著衰退。

更为根本的挑战在于专家标注数据的极端稀缺性及其高昂的获取成本。与 ImageNet 等具备海量标注资源的计算机视觉任务不同，EEG 数据的采集依赖于专业设备与受控环境，其数据标注需依赖领域专家^[4-5]。以运动想象或情绪识别等任务为例，单次试验通常仅能对应一个有效标签，这直接导致多数数据集仅包含数十至数百个样本^[6]。此种小样本困境使得复杂的深度网络极易因参数过多而陷入过拟合，难以捕获具有稳健泛化能力的本质特征。

1.2 数据增强的必要性与目标

面对上述挑战，数据增强技术从以数据为中心的人工智能这一视角出发^[7]，提供了一条关键路径。其核心逻辑并非如传统去噪或滤波方法那样旨在提升单一样本的质量，而是通过系统性地扩充与变换训练数据集，来更充分地覆盖数据的潜在分布。这种方法旨在构建一个在分布层面上更具多样性与包容性的训练环境，从而增强模型学习的鲁棒性。

具体而言，在 EEG 数据分析中引入数据增强旨在实现以下四个关键目标：

- (1) **缓解过拟合**：通过增加训练数据的多样性，迫使模型学习更普适的特征，而非记忆有限的训练样本。
- (2) **提升泛化能力**：特别是在跨被试和跨会话场景下，增强技术可以隐式地模拟个体差异，从而提升模型的域泛化性能^[2-3]。

(3) **平衡类别分布**: 对于某些极度不平衡的任务, 增强技术可以针对性地生成少数类样本, 避免模型预测偏向多数类。

(4) **增强模型鲁棒性**: 对训练数据施加可控的扰动或人工噪声, 引导模型学习对输入数据中非关键性微小变差保持不敏感的特性, 提升模型在实际应用场景中面对未见的噪声、伪迹或分布外样本时的稳定性与可靠性。

自动化数据增强策略^[8]的出现, 将数据增强从一个依赖于专家经验的技巧变为一个可学习的模型组件。

1.3 本文组织结构

本文旨在融合软件工程与机器学习的跨学科视角, 系统性地梳理 EEG 数据增强技术的演进脉络、前沿进展及其工程实践。第 2 章将依据技术范式的演进顺序, 依次剖析确定性增强、正则化增强、概率生成增强以及隐式增强这四类核心方法; 第 3 章重点关注表征物理约束、评估体系缺失以及工程部署瓶颈三大现实挑战; 第 4 章则通过构建小样本、类别不平衡、高个体差异及实时性约束四类典型数据困境, 检验不同增强策略的效能边界。第 5 章归纳总结了技术演进的内在规律, 并进一步展望了轻量化生成、多模态信息引导以及标准化评估体系等关键未来研究方向。为清晰呈现本文的整体逻辑框架, 图1-1系统性地描绘了 EEG 数据增强技术的范式演进路径及其与工程实践环节的关联。

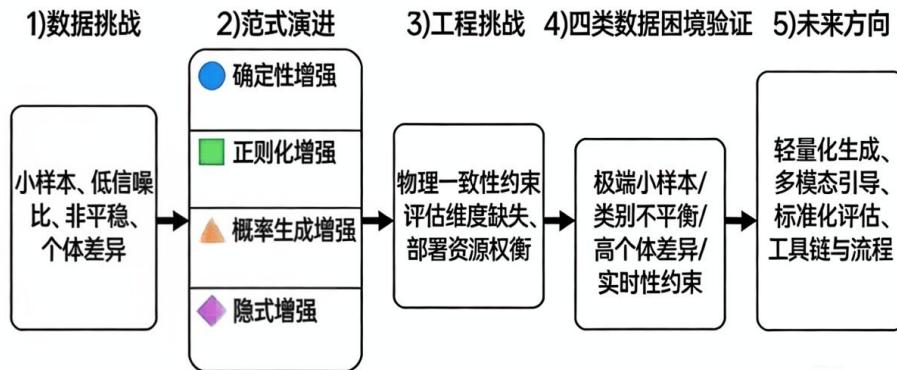


图 1-1: EEG 数据增强：演进脉络和工程实践路线图

2 EEG 数据增强的技术分类与演进

为清晰刻画技术演进脉络, 本文将 EEG 数据增强方法划分为四大范式, 其核心差异在于增强操作的生成性、语义性与集成深度:

(1) **确定性增强**: 通过预设的信号处理算子(如时移、频带交换)对单个样本进行可逆变换, 不引入新语义, 计算高效且生理可解释性强;

- (2) **正则化增强**: 通过对两个或多个样本进行线性/非线性插值（如 Mixup），在输入或特征空间构造软样本，以平滑决策边界，本质上是一种正则化策略；
- (3) **概率生成增强**: 通过学习真实数据分布 $P(X, Y)$ ，利用生成模型（如 GAN、扩散模型）合成具有新语义的逼真样本，显著扩充数据多样性；
- (4) **隐式增强**: 不再显式生成样本，而是将增强操作作为自监督预训练的代理任务（如对比学习中的视图构建），使模型在无标签数据中学习不变表示。

下文将依此框架，系统剖析各类方法的技术细节、代表性工作与适用边界。这四大范式的逻辑关系与核心差异如图2-1所示。

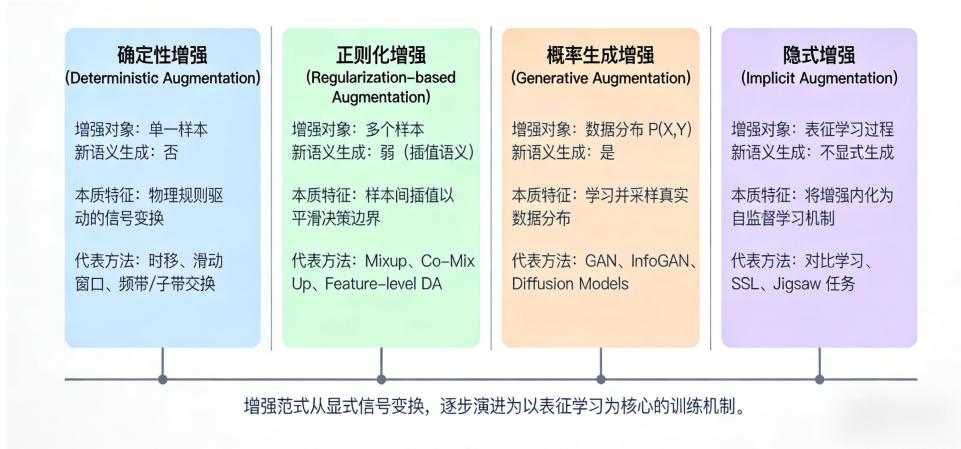


图 2-1: EEG 数据增强四范式

2.1 确定性增强：基于物理规则的显式变换

基于信号处理的确定性增强，是脑电图分析领域最早得到应用的数据增强范式，也是当前工业实践中最为稳健可靠的预处理与增强手段之一。该方法的核心在于不依赖于对数据分布的统计建模，而是依据脑电信号在时域、频域及时频域中所呈现的已知物理特性，通过预设的几何变换或确定性信号处理算子来生成新样本。Moghadam 等人^[7]所倡导的以数据为中心的人工智能理念与此高度契合，其在 SEED-VII 数据集上的实验表明，即使不改变模型架构，仅通过参与者引导的伪迹滤除与系统化的确定性增强，即可获得优于某些复杂模型的性能。这一发现进一步巩固了此类方法作为整个技术体系基石的工程地位。

在时域层面，滑动窗口及其各类变体技术是应对长程信号分段与数据扩充需求的首选方法。叶晓雅等人^[9]在构建轻量级多分支融合网络时，便借助滑动窗口技术有效缓解了脑机接口数据集样本数量不足的局限，从而提升了模型对运动想象信号的解码性能。谷学静等人^[10]在其设计的双分支时空卷积网络中，引入了一种改进的滑动窗口策略，并结合注意力机制，共同强化了对信号的特征表达能力。同时，Zhou 等人^[11]通过将滑动窗口技术与时间卷积网络相结合，有效增加了训练样本的时序多样性，从而显著提升了

运动想象任务的解码性能。另一方面，针对稳态视觉诱发电位（SSVEP）信号对数据长度高度敏感的特性，Zhang 等人^[12]提出了一种基于改进的任务相关成分分析（TRCA）框架的数据长度适配方法。该方法结合了锁相时移的数据增强策略，有效缓解了被试内及跨被试神经响应存在的差异性所导致的模型泛化难题。

在频域与变换域的增强策略层面，核心目标在于通过模拟信号在频谱上的合理扰动或特征重构，提升模型对频带偏移等变化的适应能力。为达成此目标，Du 等人^[13]提出了一种时频域联合增强的多尺度特征融合算法。该方法首先对经独立成分分析（ICA）去噪后的信号，分别施加时域与频域的增强处理，随后从中提取小波包能量特征进行融合。这一综合方案有效缓解了因样本量有限而导致的分类性能波动问题。还有 Zheng 等人^[14]提出的一种基于小波包分解的合成增强方法。该方法首先利用小波包分解将原始信号解构为低方差的稳定分量与高方差的动态分量。在此基础上，通过对不同子带成分进行有选择的交换与重组，能够生成在保留事件相关同步关键特征的同时，有效模拟信号内在变异的合成样本。这一方法在显著减少所需传感器数量的情况下，仍能维持较高的分类精度。

此外，信号统计特性分析与多维重构技术也被引入增强流程。Liao 等人^[15]提出了一种基于高斯混合模型的增强方法，其核心在于分解同类样本，并交换由概率系数加权的特征矩阵列向量，所生成的新样本在 t-SNE 可视化中呈现出更为紧凑的时空分布。在涉及多感官融合的研究中，Xia 等人^[4]针对味觉刺激 EEG 数据稀缺的难题，提出了一种时空重构数据增强方法，该方法通过对信号的时空维度特征进行解构与重组，有效丰富了训练数据的多样性。确定性增强往往是高性能现代架构的前置基础，例如 Li 等^[16]提出的 RCA-Conformer 架构，虽然利用了 Transformer 的全局建模能力，但仍需依赖稳健的特征输入来防止过拟合，确定性增强在此类混合模型中至关重要。

尽管确定性增强具备高稳定性与低计算开销的优势，但其本质是对原始信号流形的局部扰动。在极端小样本场景或需要模拟显著个体差异的任务中，这种方法难以生成具有新语义信息的样本，泛化能力提升有限。因此，其更适合作为其他增强范式的基础预处理模块，而非独立解决方案。表 2-1 进一步总结并对比了主流确定性增强方法的操作逻辑与适用场景。

2.2 正则化增强：基于样本间插值的软增强

为了突破单样本变换的局限性，技术范式向样本间插值演进，该范式引入了混合（Mixup）的概念，假设在特征空间或输入空间中，样本间的线性插值点仍然具有语义意义，从而通过软化标签实现正则化。

Mixup 及其变体在处理类别不平衡和提升鲁棒性方面表现优异。He 等^[17]在癫痫发作检测的系统性研究中，深入评估了 Mixup、SuperMix 和 Co-MixUp 三种策略，发现 Co-MixUp 能最大化混合样本与源样本，极大地缓解了 EEG 监测中严重的类别不平衡问题。在运动想象领域，Ding 等^[13]则将 Mixup 策略引入了深度卷积网络 MixedCNN，实验表明经连续小波变换（CWT）处理后的样本结合 Mixup，能使分类准确率提升至 93.57%。此外，Han 等^[18]在针对 ADHD 的 MSRLNet 网络中，引入了特征级数据增强，

表 2-1: EEG 确定性数据增强方法对比

文献	应用任务	增强操作类型	核心增强机制	关键约束条件	工程属性
叶晓雅等, 2025 ^[9]	运动想象	时域切分	滑动窗口重组	跨通道同步: 是; 同一 trial: 是; 同类别: 是	实现简单, 易于部署; 仅通过时间片段重组扩充样本
谷学静等, 2025 ^[10]	运动想象	时域切分	改进滑动窗口切分	跨通道同步: 是; 同一 trial: 是; 同类别: 是	有助于增强时序特征稳定性; 效果依赖窗口参数设计
Zheng et al., 2025 ^[14]	运动想象	子带操作	WPD 子带交换后信号重构	跨通道同步: 是; 同一 trial: 是; 同类别: 是	能较好保持 ERD/ERS 相关特征; 难以突破原始数据分布
Du et al., 2025 ^[13]	运动想象	时频联合	时频多尺度扰动	跨通道同步: 是; 同一 trial: 是; 同类别: 是	提升频谱鲁棒性; 增强策略依赖经验设定
Liao et al., 2025 ^[15]	运动想象	统计特征	GMM 特征分解与交换	跨通道同步: 是; 同一 trial: 否; 同类别: 是	改善类内分布紧致性; 统计建模假设具有适用边界
Xia 等, 2025 ^[4]	多感官 认知	时空重构	时空维度特征重构	跨通道同步: 是; 同一 trial: 是; 同类别: 是	在小样本条件下提升数据多样性; 不引入分布外样本
Zhang et al., 2025 ^[12]	SSVEP	时移	锁相时移增强	跨通道同步: 是; 同一 trial: 是; 同类别: 是	有效适配不同数据长度; 适用范围主要限于稳态诱发任务
Zhou et al., 2025 ^[11]	运动想象	时域切分	滑动窗口扩充样本并结合 TCN 建模	跨通道同步: 是; 同一 trial: 是; 同类别: 是	提升训练样本多样性与时序建模效果; 增强形式成本较为基础
Zhang et al., 2025 ^[6]	运动想象	预处理增 强	采用确定性增强构 建稳健特征输入	跨通道同步: 是; 同一 trial: 是; 同类别: 是	有助于缓解过拟合并稳定模型训练; 增强并非其主要研究对象

在 CNN-GRU 提取的高维特征空间内进行扰动与混合, 进一步验证了在特征流形上进行增强的有效性。

多模态融合也是一种广义的信息增强。Liao 等^[15]提出的脑肌电 (EEG-EMG) 融合方法, 通过注意力机制动态分配双模态权重, 利用肌电信号增强了脑电信号在单侧肢体运动解码中的特征表达能力, 弥补了单一模态的信息缺失。针对跨被试场景下的分布差异, Liu 等^[19]提出了基于被试聚类的域适应增强策略, 将相似情感响应模式的被试聚类并在类内进行源域信息的迁移, 这种策略在逻辑上类似于在特定的流形上进行样本插值。

随着增强策略的增多, 自动化数据增强应运而生。Cubuk 等^[8]在图像领域的开创性工作启发了 EEG 研究者。Rommel 等^[20]提出了 CADDA (类可微自动数据增强), 针对 EEG 信号特性设计了可微的增强操作搜索空间, 实现了针对特定任务的最优策略自动搜索。类似地, Zhou 等提出的 AutoAugHAR 框架, 设计了针对传感器数据的两阶段梯度优化流程, 证明了自动化策略在跨被试泛化中具有超越人工设计策略的潜力。表2-2对混合插值与自动增强这两类正则化策略的原理与效果进行了对比展示。

2.3 概率生成增强: 从 GAN 到扩散模型

概率生成增强旨在学习真实 EEG 数据的联合分布 $P(X, Y)$, 并通过采样生成新样本。该范式主要包括生成对抗网络与扩散模型两大技术路线, 他们在训练稳定性、生成质量与计算成本上存在显著差异。

表 2-2: EEG 正则化数据增强方法对比

文献	应用任务	增强操作类型	核心增强机制	关键约束条件	工程属性
He 等, 2025 ^[17]	癫痫检测	样本插值	Mixup / SuperMix / Co-MixUp 样本与标签联合插值	同类别约束: 是; 插值权重受显著性引导	有效缓解类别不平衡; 对插值策略设计较敏感
Ding 等, 2025 ^[13]	运动想象	输入级插值	CWT 特征上进行 Mixup	需保持时频表示一致性	提升分类性能; 依赖前置时频变换质量
Han 等, 2025 ^[18]	ADHD 识别	特征级插值	高维特征空间扰动与混合	依赖稳定特征提取器	在特征流形上增强泛化; 解释性较弱
Liao 等, 2025 ^[16]	运动解码	多模态融合	EEG-EMG 特征加权融合	模态时间同步; 权重动态分配	弥补单模态信息不足; 依赖额外传感器
Liu 等, 2021 ^[2]	情感识别	被试级插值	被试聚类后类内特征迁移	需保证被试聚类合理性	提升跨被试泛化; 对聚类质量敏感
Rommel 等, 2022 ^[20]	多任务 EEG	自动化正则化	可微增强策略搜索 (CADD)	搜索空间需可微	减少人工经验依赖; 训练流程复杂
Zhou 等, 2024 ^[11]	传感器行为识别	自动化增强	两阶段梯度优化的增强策略搜索	需额外验证集参与优化	跨被试泛化性能突出; 计算开销较高

2.3.1 生成对抗网络 (GAN)

GAN 及其变体是早期 EEG 生成的主流框架。Habashi 等^[21]的综述系统梳理了 GAN 在运动想象、P300 及癫痫检测中的应用, Du 等^[13]提出基于 DCGAN-GP 的方法, 将 EEG 转为二维时频图进行生成; Song 等^[22]进一步结合条件 GAN 与 SE 注意力机制, 实现类别可控生成, 为提升特征解耦能力, InfoGAN 被引入 MI 任务^[23], 此外, VAE-GAN 混合架构 (如 SSVAE-CGAN^[24]、DEVAE-GAN^[25]) 通过双编码器分别建模时空潜在变量, 在情感 EEG 生成中展现出更强的分布覆盖能力。

然而, GAN 在 EEG 生成中仍面临训练不稳定、梯度消失、评估困难三大瓶颈, 尤其在高维时序信号上易出现高频噪声或相位失真, 或在小批量 EEG 数据上易出现收敛困难。

2.3.2 扩散模型 (Diffusion Models)

近年来, 扩散模型凭借其训练稳定性高、样本多样性好、频谱保真度强等优势, 逐渐成为 EEG 生成的新范式。Zhang 等构建基于 DDPM 的生成框架, 在视觉刺激解码任务中提升了 9.56% 的准确率; Moghadam 等^[7]提出的卷积注意力扩散模型 (CADM) 专门针对抑郁症检测中的小样本问题, 生成的时频特征能有效增强 Transformer 的鲁棒性。在跨模态任务中, 离散扩散模型首次被用于脑电到语音合成^[26], 克服了非侵入式信号质量低的挑战。

与 GAN 相比, 扩散模型通过逐步去噪过程建模数据分布, 不易陷入模式崩塌, 且生成样本在 δ/θ 频段的功率谱密度更接近真实 EEG^[7]。但其推理速度慢、计算开销大 (通常需数百步迭代), 限制了在实时 BCI 系统中的部署。

总体而言, GAN 适合对生成速度要求较高、样本规模中等的场景; 而扩散模型更适合对生成质量与生理真实性要求严苛的离线临床诊断任务。为了厘清两者的应用边界,

表2-3详细对比了 GAN 与扩散模型在训练稳定性、生成质量及计算开销上的关键差异。

表 2-3: 基于概率生成模型的 EEG 数据增强方法对比

文献	应用任务	增强操作类型	核心增强机制	关键约束条件	工程属性
Du 等, 2024 ^[13]	运动想象	GAN 生成	基于 DCGAN-GP 的时频图生成与重构	对抗训练需稳定；保持时频结构一致性	缓解模式崩塌；训练稳定性仍受限
Song et al., 2024 ^[22]	多类 EEG 分类	条件 GAN	条件 GAN 结合注意力机制进行类别可控生成	条件标签与生成过程强耦合	生成可控性强；模型结构复杂
肖 楠 等, 2025 ^[23]	运动想象	GAN 生成	基于互信息约束的潜变量控制生成 (InfoGAN)	潜变量需与 ERD/ERS 特征对应	支持生理特征可控生成；调参复杂
袁 凯 烽 等, 2025 ^[24]	运动想象	VAE-GAN 混合	半监督 VAE 与 CGAN 联合建模时空潜变量	潜变量解耦需合理	改善分布覆盖能力；训练流程复杂
Tian et al., 2023 ^[25]	情感识别	VAE-GAN 混合	双编码器建模时域与空间特征	编码器解耦依赖数据质量	提升生成多样性；计算代价较高
Zhang 等, 2025 ^[12]	视觉刺激 解码	扩散生成	基于 DDPM 的逐步去噪生成	需多步反向采样	生成质量高；推理速度慢
Moghadam 等,2025 ^[7]	抑郁症检 测	扩散生成	卷积注意力扩散模型 (CADM) 生成时频特征	需保持频谱生理一致性	小样本鲁棒性强；资源消耗较高
方 元,2025 ^[26]	跨模态合 成	扩散生成	离散扩散模型实现 EEG 到语言建模	模态对齐要求高	拓展跨模态应用；系统复杂度高

2.4 隐式增强：自监督与对比学习中的增强内化

数据增强的最新演进方向不再局限于“显式地生成样本”，而是将增强操作内化为模型学习特征不变性的核心机制——即自监督学习（Self-Supervised Learning, SSL）和对比学习（Contrastive Learning）。

对比学习通过构造“正样本对”（增强视图）来拉近其特征距离。Song 等^[27]在 MST-DAN 模型中构建了无负样本的对比学习框架，利用随机裁剪和滤波作为增强策略，仅需 50% 的标注数据即可达到全量数据的性能。Li 等^[28]提出了面向脑电时序建模的鲁棒预训练框架，通过引入“额外噪声负样本”和“跨域重构”任务，显式建模噪声分布，使模型在面对带通滤波等预处理差异导致的分布偏移时保持鲁棒。针对癫痫检测，Li 等^[29]设计了时间与上下文对比模块，利用增强后的数据挖掘长程时间依赖性。

在图结构与复杂任务中，增强策略变得更加结构化。Li 等^[19]提出的 GMSS 模型引入了“拼图任务”（Jigsaw Puzzle），包括空间拼图和频率拼图作为自监督任务，迫使模型学习 EEG 的内在拓扑结构和关键频段。Ye 等^[30]提出的 DS-AGC 框架，则结合了半监督对抗图对比学习，利用双流架构提取结构与非结构特征，解决跨被试情感识别中的域偏移问题。针对跨时段脑纹识别，Wang 等^[3]提出的 DAGCNet 引入了特征层面的随机权重扰动作为增强手段，并结合三元组对比损失，有效提取了时不变的身份特征。表2-4归纳了隐式增强范式中典型的对比学习架构与视图构建策略。

表 2-4: EEG 隐式数据增强方法对比

文献	应用任务	增强操作类型	核心增强机制	关键约束条件	工程属性
Song 等 ^[27]	多任务 EEG	视图构造	随机裁剪与滤波构造正样本对的无负样本对比学习	同一原始样本视图一致性	显著降低标注需求；对增强策略较敏感
Li 等 ^[28]	时序 EEG 建模	噪声对比	引入噪声负样本与跨域重构任务进行鲁棒预训练	噪声分布需合理建模	提升对预处理差异的鲁棒性；训练流程复杂
Li 等 ^[29]	癫痫检测	时间对比	时间与上下文对比模块挖掘长程时间依赖	保持事件相关结构	强化时序建模能力；任务依赖性较强
Li 等 ^[19]	多通道 EEG	拼图任务	空间拼图与频率拼图的自监督学习	子带划分需符合生理频段	学习拓扑与频谱结构；解释性有限
Ye 等 ^[30]	情感识别	图对比	半监督对抗图对比学习的双流架构	图结构与被试划分合理	提升跨被试泛化；模型结构复杂
Wang 等 ^[3]	脑纹识别	特征扰动	特征层随机权重扰动结合三元组对比损失	扰动强度需受控	提取时不变身份特征；参数敏感

3 关键技术挑战与工程实践

EEG 数据增强技术虽然在理论上缓解了小样本困境，但要将其转化为可靠的工程能力，仍需跨越从实验室到规模化部署的鸿沟。当前制约技术落地的核心矛盾，已从“能否提升准确率”转向“是否安全、可信、高效”^[31]。本节将系统说明遇到的三大关键挑战：增强操作必须满足的物理一致性约束、评估体系缺失导致的质量误判风险，以及工程部署中的典型陷阱，并提出可操作的应对策略。

3.1 增强操作与 EEG 表征的物理一致性约束

脑电信号的表征形式直接划定了数据增强的“安全边界”。随着建模范式从简单的 2D 时序矩阵向保留拓扑的 3D 张量乃至图结构演进，增强算法的设计复杂度呈指数级上升^[19]。早期的 2D 表征（通道 × 时间）虽然计算高效，但往往忽视电极间的空间拓扑。在这种表征下，简单的时移或裁剪若不被加以限制，极易破坏通道间的相位同步性，致使模型学到非生理性的噪声特征^[2]。

为规避这一风险，当前的工程实践更倾向于采用联合增强策略。例如，在处理时频域数据时，必须确保时域的切片拼接与频域的节律交换同步进行，以维持信号在物理空间上的邻域一致性^[32]。此外，针对 2D 表征的严格约束还包括：同一原始样本的增强子片段绝不能跨越训练集和测试集，否则将导致严重的数据泄露^[6]。

对于更复杂的 3D 及图结构表征，增强操作面临的约束就更为严格。研究表明，生成式模型（如 3D-GAN）只有在维持运动想象任务的 μ 波抑制特征等空间一致性时，才能有效提升分类准确率^[32]。而在最新的图对比学习框架中，增强策略（如随机滤波或加噪）必须在严格保持图拓扑结构的前提下进行^[30]。这要求算法必须具备区分“弱增强”与“强增强”的能力，以避免破坏节点间的连接权重，保证跨被试的泛化能力^[29]。图 3-1 形象地揭示了若忽视这些物理一致性约束，可能导致的信号失真与工程失效风险。

进一步地，我们可将上述约束归纳为三条通用设计原则：

- (1) **时域操作必须全局同步**：禁止通道独立扰动以维持相位一致性；



图 3-1: EEG 数据增强的工程约束与失效风险

- (2) **频域变换需保持事件锁定特性**: 子带交换应在同一时间窗内完成^[1];
- (3) **图结构增强不得改变功能连接的相对强度**: 尤其在默认模式网络 (DMN) 等关键通路中^[3]。

违反任一原则，即使提升训练准确率，也可能导致模型在真实场景中失效。

3.2 多维度评估体系：从信号保真到任务效用

在缺乏标准化评估体系的现状下，过度依赖“分类准确率”已成为评估生成质量的主要陷阱^[24]。工程经验表明，分类准确率不仅无法区分模型是学习了鲁棒特征还是记忆了增强样本的分布，甚至可能掩盖过拟合风险——当生成样本比例超过一定阈值（如 70%）时，准确率的边际收益往往趋于平缓，甚至出现性能倒退^[5]。

因此，构建一个能反映信号本质的分层次、可量化的多维度评估体系，就是突破这一瓶颈的关键。

首要的评估维度是生理频谱保真度，高质量的增强样本必须在频谱特性上复现真实脑电，生成样本必须保持与真实 EEG 一致的 ERD/ERS 模式，否则模型将学习到错误的特征^[24]。实验证实，相比标准 MixUp 导致的频谱失真，Co-MixUp 等改进方法能更好地保持 δ 和 θ 频段的功率谱密度^[25,33]。具体可采用功率谱密度均方误差 (PSD-MSE) 作为量化指标，其计算可基于 MNE-Python 的多维度谱估计函数。

我们还需关注整体数据集的分布一致性，这时直接套用图像领域的 FID 指标会导致评估偏差，更合理的做法是采用针对 EEG 特性改进的指标（如基于 EEGNet 特征的 EEG-FID），或使用切片 Wasserstein 距离 (SWD) 来捕捉时频特性的分布差异^[24,34]。

最终，这些指标应被整合到一起，在关注分类性能增益的同时同步监控频谱一致性、样本多样性及训练稳定性^[12]。图3-2展示了这一评估框架，只有当生理保真度与分布一致性达标后，下游任务的性能提升才具有实际意义，否则高准确率可能源于模型对生成伪迹的过拟合。

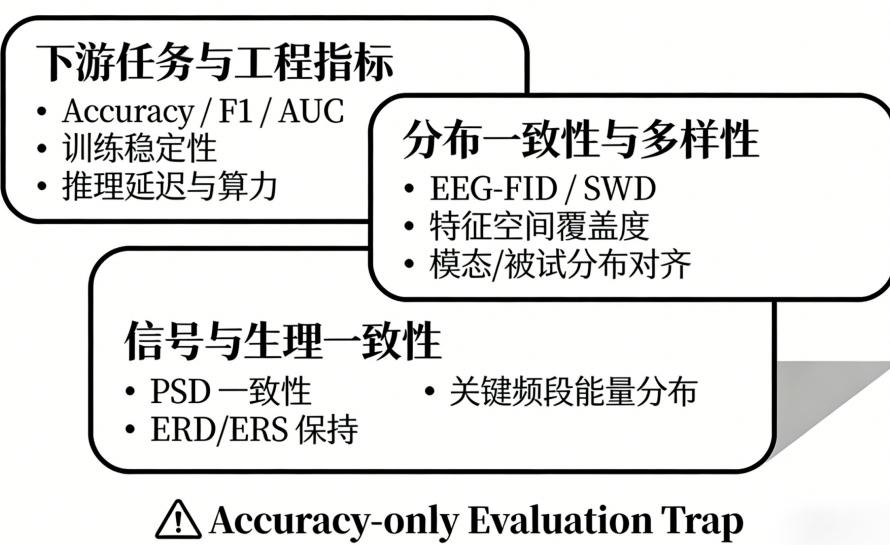


图 3-2: EEG 数据增强的多维评估框架

3.3 工程部署中的三大陷阱与应对策略

在实际部署中，除了算法层面的挑战，还需警惕数据泄露、边际效应递减与计算资源消耗三大工程陷阱。因此，我们需要做到以下几点：

首先是建立严格的数据隔离机制。数据泄露是模型评估失效的重要原因，最常见的错误是在数据划分前进行全局增强，因此工程实践必须遵循先划分、后增强的原则，确保每个原始样本及其增强子片段严格限制在单一数据集中^[6]，在跨被试场景必须确保同一被试的数据不会同时出现在正负样本对中或通过交叉验证设计确保受试者轮流作为目标域^[30]。

EEG 信号的类内多样性有限，这意味着增强规模并非越大越好，多项研究证实^[5]生成样本比例存在一个最优值（通常为原始数据的 70% 左右），一旦超过此阈值，过度增强会导致模式崩溃，引发样本同质化，降低模型的泛化性能^[32]，动态调整增强强度能有效解决这个问题^[27,29]，同时可引入样本多样性监控机制，定期计算生成样本在 t-SNE 空间的聚类熵，低于阈值则自动降低生成强度。

最后，生成式模型虽然生成内容质量高，但在实时系统中经常难以落地^[35]，可以采取非对称的轻量化策略和分阶段部署，在算法选择上优先采用计算成本仅为原始信号生成 40% 的特征空间增强（如 MixReg）或在架构层面采用离线重生成、在线轻增强的两阶段部署方案^[35]，同时在训练流水线中引入针对增强操作的结果缓存机制能有效降低重复计算负荷^[20]，在有限算力下实现性能与效率的平衡。

这些实践构成了 EEG 数据增强的工程框架，确保了技术在提升模型性能的同时，具备系统级的可靠性与可部署性^[20,26]。

4 数据增强的有效性验证：基于典型数据困境的实证分析

本文第 2 节系统梳理了 EEG 数据增强的技术范式，第 3 节提出了评估与工程准则，但最终仍需通过真实任务场景验证其有效性，但是有效性并非普适，不同增强方法在不同数据困境下表现迥异，本节不再按应用领域划分，而是依据四类典型数据挑战组织案例反向揭示各类增强范式的适用边界与作用机制。

4.1 极端小样本场景下的生成式增强优势

当每类训练样本少于 50 个时（常见于运动想象、罕见认知任务），传统模型极易过拟合。此时，概率生成增强展现出重要价值。肖楠等^[23]提出的 DCIMGAN（基于 InfoGAN）通过最大化生成信号与潜在变量的互信息，实现了对 MI-EEG 中 ERD/ERS 特征的可控生成。在 BCI Competition IV 2a 数据集（每类仅约 72 trials）上，该方法使 EEGNet 的平均准确率提升 6.2%，显著优于滑动窗口等确定性增强。类似地，夏秀鑫^[4]在嗅觉、味觉与联觉等超小样本认知任务（部分类别 <20 样本）中，采用时空重构增强有效提升了识别性能，证实生成式方法能突破原始数据流形边界。

扩散模型在离线小样本场景中潜力巨大，汪子凯等^[35]针对抑郁症 EEG 数据稀缺问题，提出卷积注意力扩散模型（CADM），生成的时频特征在 MODMA 数据集上使 Vision Transformer 准确率提升 8.7%。

4.2 严重类别不平衡场景中的正则化与定向生成

在癫痫检测等任务中，病理事件占比常低于 1%，导致模型偏向多数类，针对性增强少数类成为关键，胡文蓉^[5]通过过采样与生成病理样本，使 1DCNN-BiLSTM 模型在 CHB-MIT 数据集上将发作检测 F1-score 从 0.62 提升至 0.81，He 等^[1]系统比较 Mixup、SuperMix 与 Co-MixUp 后发现，Co-MixUp 通过显著性图引导插值权重，能更好保留癫痫高频振荡特征，在长程监测中正确率提升达 9.3%。

生成模型亦可定向合成少数类。Pan 等利用 ACGAN 生成癫痫发作期时频图像，丰富了 CNN-ELM 的训练集；Du 等^[13]的 DCGAN-GP 则通过梯度惩罚稳定训练，避免模式崩塌导致的假阳性。这些工作共同表明：在类别极度不平衡时，增强策略必须与任务判别特征对齐——简单加噪或随机插值反而会稀释关键模式。

4.3 高个体差异下的跨被试泛化：隐式增强的崛起

情感识别、跨被试 MI 等任务中，个体间神经响应差异远大于类间差异，导致模型泛化困难。此时，显式增强（如 Mixup、GAN）效果有限，因其难以模拟真实的跨被试分布漂移。相反，隐式增强通过自监督学习提取不变表示，展现出更强鲁棒性。

Zhang 等在跨时段脑纹识别中提出 DAGCNet，采用特征级随机权重扰动构建增强视图，并结合三元组对比损失，有效提取时不变身份特征，在私有数据集上跨会话准确率达 92.4%。Li 等^[19]的 GMSS 模型设计“空间拼图”与“频率拼图”自监督任务，迫

使模型学习 EEG 内在拓扑与关键频段，在 SEED 情感数据集上跨被试性能超越监督基线 11.2%。此外，Liu 等^[2]的 DASC 策略虽属域适应，但其在被试聚类流形上进行信息迁移的思路，本质上也是一种结构化插值，可视为正则化增强的高级形式。

这些研究表明：当个体差异主导数据分布时，增强的目标应从“扩充样本”转向“解耦身份与任务特征”，而自监督框架为此提供了天然载体。

4.4 实时性约束下的轻量化增强可行性

在线 BCI 系统要求端到端延迟 <100ms，排除了扩散模型等重型生成器。此时，确定性增强与特征级正则化成为首选。霍首君等^[36]在 MI 解码中采用 STFT+CWT 生成时频图，并引入 Mixup 平滑决策边界，在 BCI Competition II dataset II 上将 CNN 准确率提升至 93.57%，且推理延迟仅增加 3ms。鲁博洋^[37]针对下肢 MI 的空间敏感性，仅对中央区/顶区电极进行通道级增强，避免全局操作破坏局部皮层特征，提升 RCNN 解码精度 4.8%。

多模态融合亦可视为一种高效增强。张家政^[6]在单侧肢体运动解码中，对 EEG 与 EMG 同步施加时间偏移与加噪，通过注意力机制动态融合，显著提升模型对信号漂移的抗干扰能力。此类方法不增加样本数量，但通过多源信息互补增强特征表达，在资源受限场景极具价值。

4.5 总结：增强策略与数据困境的匹配原则

基于上述针对各类典型应用场景的实证分析，我们归纳出了增强策略与特定数据挑战之间的内在对应关系。表4-1直观地展示了这一“数据困境 × 增强范式”的匹配矩阵，清晰地界定了不同约束条件下的推荐技术路线：在极端小样本场景下，需依靠概率生成增强来突破原始数据的流形边界以合成新语义；面对严重的类别不平衡，正则化策略配合定向生成能最有效地保留少数类判别特征；针对高个体差异带来的泛化难题，隐式增强提供了学习身份不变表示的最佳途径；而在严苛的实时性约束下，确定性增强与特征级增强则是平衡解码性能与计算开销的首选方案。

表 4-1：数据困境与 EEG 数据增强范式的匹配关系矩阵

数据困境	确定性增强	正则化增强	概率生成增强	隐式增强
极端小样本	适配度：低 说明：仅重组原有样本，难以显著扩展分布	适配度：中 说明：插值可平滑决策边界，但语义扩展有限	适配度：高 说明：可通过步扩散或条件生成显式扩展样本空间	适配度：中 说明：通过表征约束缓解过拟合，但依赖预训练
严重类别不平衡	适配度：低 说明：无法针对少数类定向增强	适配度：高 说明：Co-MixUp 等策略可显著缓解类别偏置	适配度：高 说明：条件生成可定向补充少数类样本	适配度：中 说明：对不平衡问题为间接缓解
跨被试分布差异	适配度：中 说明：可通过投影或归一化进行部分校正	适配度：中 说明：被试聚类或域内插值可缓解差异	适配度：中 说明：生成分布泛化存在不确定性	适配度：高 说明：不变性学习可显式抑制被试差异
实时性约束 (BCI)	适配度：高 说明：计算开销低，易于在线部署	适配度：低 说明：插值与混合增加在线复杂度	适配度：低 说明：生成推理成本高，难以实时运行	适配度：高 说明：轻量对比约束可嵌入训练阶段

综上所述，领域内并不存在一种普适的“最优”增强方法，只有针对特定数据特征与工程约束的“最适”策略。研究者应首先准确诊断下游任务所面临的核心数据困境，参考图 9 所示的匹配关系进行范式选型，方能实现模型性能与工程效率的全局最优。

5 总结与展望

5.1 技术演进总结

本文系统性地回顾了本文系统性地回顾了 EEG 数据增强技术从传统方法到前沿范式的演进历程。这一历程清晰地展现了一条从显式模拟到隐式学习，从数据层面的扩充到学习范式变革的技术发展路径。

早期，基于信号处理的确定性增强方法（如小波包合成^[32]）凭借其低计算开销和高可解释性，为领域奠定了基石。随后，基于样本插值的正则化增强思想（如 Mixup 及其变体^[36]）通过在线插值简单而有效地引入了正则化，缓解了过拟合。

基于生成模型的概率增强 成为了近年来的主流方向，其中 GAN 系列（如 InfoGAN^[25]，WTGAN^[14]）展现了强大的数据生成能力，尽管其训练不稳定性与模式崩塌问题一度成为瓶颈；而新兴的扩散模型^[38] 则以其训练稳定性和高质量生成效果，显示出巨大的潜力。

最具革命性的范式转变来自于基于自监督学习的隐式增强，它不再将增强视为独立的预处理步骤，而是将其作为预训练任务的核心机制（如对比学习^[27,29]），通过构建代理任务让模型从未标注数据中自我学习，从根本上减少了对大量标注数据的依赖。

5.2 当前局限与挑战

尽管数据增强技术取得了显著进展，但该领域仍面临若干严峻挑战，制约着其在科研与工业界的更广泛应用：

缺乏统一的评估协议： 当前研究大多以最终分类准确率作为单一评判标准，缺乏针对生成样本质量本身的标准化指标。正如第 3.2 节所述，必须建立包含生理保真度（PSD、ERD/ERS）、分布一致性（EEG-FID）与任务效用的多维评估体系。

生成样本的生理真实性存疑： 大多数数据驱动的生成模型（如 GAN、扩散模型）可能无法保证生成的 EEG 片段在神经科学上具有明确的生理意义^[39]。其是否真实反映了特定的脑认知活动模式，而非仅仅是统计上的拟合，仍需神经科学层面的验证。

在实时 BCI 系统中部署困难： 许多先进的生成模型（如扩散模型^[36]）和复杂的数据增强流程计算开销巨大，难以满足实时脑机接口系统对低延迟的苛刻要求。第 3.3 节提出的“离线生成 + 在线缓存”“特征级增强”等非对称策略，是走向实用的关键。

5.3 未来研究方向

基于当前现状与挑战，我们认为 EEG 数据增强技术未来有以下几个充满前景的研究方向：

- (1) **轻量化与高效的生成模型**：探索知识蒸馏、模型剪枝、高效的网络架构（如线性 Transformer）等技术，对大型生成模型进行压缩与加速，使其能够部署在资源受限的边缘设备上^[38,40]。
- (2) **多模态引导的增强策略**：结合 fNIRS、fMRI 等多模态脑成像数据，或利用已知的神经科学先验知识（如脑功能连接图谱）来引导 EEG 数据的生成过程，有望提升生成样本的生理合理性与任务相关性^[26,35]。
- (3) **统一、全面的评估框架建设**：推动建立包含信号保真度（时域、频域）、生理合理性（如 ERD/ERS 模式^[39]）和下游任务效用在内的多维度评估基准，促进不同研究之间的公平比较与技术发展。
- (4) **开源工具库与标准化流程**：大力支持如 TorchEEG 等开源工具库的建设，将主流的数据增强算法进行模块化、标准化的实现与集成，降低研究门槛，促进实验的可复现性，推动整个领域的健康发展^[41]。实现“按需增强”。

通过在这些方向上的持续探索，EEG 数据增强技术有望从一项辅助性的“技巧”，演进成为构建下一代鲁棒、自适应、可泛化脑机智能系统的核心引擎。

参 考 文 献

- [1] HE C, LIU J, ZHU Y, et al. Data Augmentation for Deep Neural Networks Model in EEG Classification Task: A Review. *Frontiers in Human Neuroscience*, 2021, 15: 765525.
- [2] LIU J, SHEN X, SONG S, et al. Domain Adaptation for Cross-Subject Emotion Recognition by Subject Clustering//2021 10th International IEEE/EMBS Conference on Neural Engineering (NER). Italy: IEEE, 2021: 904-908.
- [3] 王欣然. 面向跨时段脑纹识别的域泛化方法研究. 杭州电子科技大学. 2025 [2025-11-29]. <https://doi.org/10.27075/d.cnki.ghzdc.2025.000420>.
- [4] 夏秀鑫. 基于深度学习的嗅觉、味觉与联觉脑电数据识别方法研究. 东北电力大学. 2025 [2025-11-29]. <https://doi.org/10.27008/d.cnki.gdbdc.2025.000007>.
- [5] 胡文蓉. 基于数据增强和深度神经网络的癫痫检测研究. 曲阜师范大学. 2025 [2025-11-29]. <https://doi.org/10.27267/d.cnki.gqfsu.2025.001008>.
- [6] 张家政. 基于脑肌电融合的单侧肢体运动想象解码方法研究. 杭州电子科技大学. 2025 [2025-11-29]. <https://doi.org/10.27075/d.cnki.ghzdc.2025.001946>.
- [7] MOGHADAM N, HEGAZY R. Data-Centric AI for EEG-Based Emotion Recognition: Noise Filtering and Augmentation Strategies. *Bioengineering*, 2025, 12(11): 1264.
- [8] CUBUK E D, ZOPH B, MANÉ D, et al. AutoAugment: Learning Augmentation Strategies From Data//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA: IEEE, 2019: 113-123.
- [9] 叶晓雅, 王秀青, 马海滨, 等. EEG-MFNet: 适用于脑电信号分析的轻量级多分支融合网络. 山东大学学报 (理学版), 2025, 60(7): 1-12.
- [10] 谷学静, 周记帆, 郭志斌. 融合注意力的双分支时空卷积脑电识别网络. 现代电子技术, 2025, 48(18): 159-164.
- [11] ZHOU Y, ZHAO H, HUANG Y, et al. AutoAugHAR: Automated Data Augmentation for Sensor-based Human Activity Recognition. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2024, 8(2): 1-27.
- [12] 张思源. 面向稳态视觉诱发电位的脑解码个体适配性技术研究. 郑州轻工业大学. 2025 [2025-11-29]. <https://doi.org/10.27469/d.cnki.gzzqc.2025.000323>.
- [13] DU X, DING X, XI M, et al. A Data Augmentation Method for Motor Imagery EEG Signals Based on DCGAN-GP Network. *Brain Sciences*, 2024, 14(4): 375.
- [14] ZHENG M, QIAN Z, ZHAO T. Motor Imagery EEG Classification via Wavelet-Packet Synthetic Augmentation and Entropy-Based Channel Selection. *Frontiers in Neuroscience*, 2025, 19: 1689647.

- [15] LIAO C, ZHAO S, WANG X, et al. EEG Data Augmentation Method Based on the Gaussian Mixture Model. *Mathematics*, 2025, 13(5): 729-751.
- [16] 李响, 艾尔肯·亥木都拉. 基于 CNN 与 Transformer 的脑电解码研究. *微电子学与计算机*, 2025. advance online publication.
- [17] 何欢欢. 基于脑电信号的数据增强与情绪识别研究. 兰州大学, 2025.
- [18] HAN Q, SONG Z, YE H, et al. MSRLNet: A Multi-Source Fusion and Feedback Network for EEG Feature Recognition in ADHD. *Brain Sciences*, 2025, 15(11): 1132.
- [19] LI Y, CHEN J, LI F, et al. GMSS: Graph-Based Multi-Task Self-Supervised Learning for EEG Emotion Recognition. *IEEE Transactions on Affective Computing*, 2023, 14(3): 2512-2525.
- [20] ROMMEL C, MOREAU T, PAILLARD J, et al. CADDA: Class-wise Automatic Differentiable Data Augmentation for EEG Signals. (2022-02-07) [2025-11-30]. <http://arxiv.org/abs/2106.13695>. arXiv: 2106.13695 [cs]. Pre-published.
- [21] HABASHI A G, AZAB A M, ELDAWLATLY S, et al. Generative Adversarial Networks in EEG Analysis: An Overview. *Journal of NeuroEngineering and Rehabilitation*, 2023, 20(1): 40.
- [22] SONG J, ZHAI Q, WANG C, et al. EEGGAN-Net: Enhancing EEG Signal Classification through Data Augmentation. *Frontiers in Human Neuroscience*, 2024, 18: 1430086.
- [23] 肖楠, 李明爱. 基于信息最大化生成对抗网络的运动想象脑电信号数据增强. *北京生物医学工程*, 2025, 44(5): 449-456.
- [24] 袁凯烽, 侯璐, 黄永锋. 基于半监督 VAE 和 CGAN 的运动想象脑电信号分类器. *传感器与微系统*, 2025, 44(2): 82-86.
- [25] TIAN C, MA Y, CAMMON J, et al. Dual-Encoder VAE-GAN With Spatiotemporal Features for Emotional EEG Data Augmentation. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2023, 31: 2018-2027.
- [26] 方元. 基于深度学习的 EEG 脑电图信号语音合成. 内蒙古大学. [2025-11-29]. <https://doi.org/10.27224/d.cnki.gnmdu.2025.000215>.
- [27] 宋飞宇. 基于时空分析和对比学习的运动想象脑电信号解码研究. 杭州电子科技大学. 2025 [2025-11-29]. <https://doi.org/10.27075/d.cnki.ghzdc.2025.000579>.
- [28] 李楚阳. 基于自监督学习的脑电图鲁棒分类研究. 哈尔滨工业大学. [2025-11-29]. <https://doi.org/10.27061/d.cnki.ghgdu.2025.004375>.
- [29] 李洁. 癫痫脑电的对比学习特征表示及用于致痫区识别的脑电预训练模型研究. 山东师范大学. 2025 [2025-11-29]. <https://doi.org/10.27280/d.cnki.gsdsu.2025.000267>.

- [30] YE W, ZHANG Z, TENG F, et al. Semi-Supervised Dual-Stream Self-Attentive Adversarial Graph Contrastive Learning for Cross-Subject EEG-Based Emotion Recognition. *IEEE Transactions on Affective Computing*, 2025, 16(1): 290-305.
- [31] 彭磊, 魏国辉, 马志庆, 等. 脑电信号情绪识别关键技术研究进展. *北京生物医学工程*, 2024, 43(2): 211-217.
- [32] 郑敏敏, 钱政康, 赵桐. 一种多尺度特征融合运动想象脑电信号分类算法——基于时频域数据增强. *莆田学院学报*, 2025, 32(2): 52-60, 70.
- [33] 乔迎晓. 基于多维特征图和深度学习的脑电信号情绪识别方法研究. *曲阜师范大学*. 2025 [2025-11-29]. <https://doi.org/10.27267/d.cnki.gqfsu.2025.000255>.
- [34] 宋春宁, 盛勇, 宁正高. 基于深度学习的运动想象脑电信号识别方法. *传感器与微系统*, 2022, 41(4): 125-128, 133.
- [35] 汪子凯, 陈景霞, 贾晓雯, 等. 用于抑郁症脑电数据增强的卷积注意力扩散模型. *软件工程*, 2025, 28(7): 64-68.
- [36] 霍首君, 郝琰, 石慧宇, 等. 基于深度卷积网络的运动想象脑电信号模式识别. *计算机应用*, 2021, 41(4): 1042-1048.
- [37] 鲁博洋. 基于卷积神经网络的下肢运动解码研究—从脑电信号角度. *东南大学*, 2022.
- [38] 黄俊洁. 基于深度学习的视觉刺激脑电信号增强-识别算法研究. *吉林大学*. 2025 [2025-11-29]. <https://doi.org/10.27162/d.cnki.gjlin.2025.002017>.
- [39] 付荣荣, 孟云, 黄晓东, 等. 基于神经质量模型的运动想象脑电数据增强. *计量学报*, 2025, 46(5): 762-768.
- [40] 黄飞. 基于 3D 卷积神经网络和生成对抗网络的运动想象脑电信号解码研究. *杭州电子科技大学*. 2025 [2025-11-29]. <https://doi.org/10.27075/d.cnki.ghzdc.2025.001444>.
- [41] 赵伟. 基于深度学习的脑电信号情感情识别研究. *天津大学*, 2021.